



**PROJETO DE AVALIAÇÃO
MODELOS DE REGRESSÃO E API DJANGO**

Requerente: SENAI

Ricardo Henrique De Bassi

Londrina, Abril de 2025

Sumário

1	Introdução	3
2	Análise Exploratória dos Dados Recebidos	3
2.1	Análise de Correlação	4
2.2	Distribuição das Variáveis Target	6
2.3	Distribuição das Features	6
3	Multicolinearidade e Análise de VIF	7
3.1	Feature Importance com Random Forest	7
3.2	Feature Importance com XGBoost	7
3.3	Considerações Finais da Análise Exploratória	8
4	Preparação dos Dados e Treinamento dos Modelos	8
4.1	Métricas Utilizadas	10
4.2	Resultados dos Testes dos Modelos	11
4.2.1	Resultados com Todas as Variáveis	11
4.2.2	Resultados com Redução de Dimensionalidade (PCA)	12
4.2.3	Resultados com Exclusão de Variáveis	12
4.2.4	Conclusão dos Testes	13
5	Características da API Django	13
5.1	Arquitetura do Sistema	13
5.1.1	Modelo de Usuário Personalizado	13
5.1.2	Modelo de Predição	14
5.1.3	Carga do Modelo de Regressão	14
5.2	Endpoints da API	14
5.3	Banco de Dados	15
6	Conclusão	15

1 Introdução

Este relatório descreve o desenvolvimento de um projeto composto por um modelo de regressão para predição de duas grandezas e uma API Django responsável pela interface de predição, visualização e gerenciamento dos dados e usuários do sistema. Considerando Modelos de Regressão, foram testados cinco modelos bem conhecidos para problemas de regressão, da biblioteca sklearn: RandomForestRegressor, GradientBoostingRegressor, Support Vector Regressor (SVR), Ridge e o famoso modelo de competições XGBoost.

A API foi projetada para ser documentada e testada no Swagger. Este documento apresenta uma análise detalhada dos modelos utilizados, os critérios de escolha do modelo final e a arquitetura da API.

A roadmap do projeto pode ser descrita por sete checkpoints principais:

- Análise exploratória dos Dados Recebidos;
- Preparação dos dados e Treinamento dos Modelos;
- Análise e Escolha do melhor Modelo de Predição;
- Desenvolvimento e Configuração da API Django;
- Testes da API pelo Swagger;
- Criação do Frontend para Interface;
- Containerização em Docker.

Cada um dos itens será descrito neste relatório e os códigos parciais foram enviados ao github. As análises detalhadas, incluindo todos os gráficos comentados e algumas tabelas complementares estão disponíveis nos notebooks.

2 Análise Exploratória dos Dados Recebidos

A etapa inicial concentrou-se na compreensão da estrutura dos dados por meio de técnicas fundamentais. Nas primeiras análises, concluiu-se que o dataset analisado é relativamente pequeno (768 linhas), com tipos de variáveis adequados (inteiros ou float), de acordo com os dados. Observou-se uma boa distribuição aparente das variáveis inteiras Orientation e Glazing Area Distribution. Esta última possui valor mínimo igual a zero, mas como a variável Glazing Area apresenta o mesmo número de zeros, entende-se que esse valor representa uma característica do problema, e não ausência de dados.

A tabela de descrição estatística mostrou alguns pontos relevantes:

- As variáveis Roof Area, Overall Height e Glazing Area podem apresentar limites superiores de medição, já que seus valores máximos coincidem com o terceiro quartil (Q3).
- As variáveis target apresentam média superior à mediana, sugerindo a existência de viés positivo na distribuição.
- Observa-se grande disparidade entre as escalas das variáveis, como por exemplo: $\text{mean}(X7) \approx 0,23$ e $\text{mean}(X2) \approx 671,70$.
- As variáveis target possuem valores máximos significativamente distantes do Q3, o que pode indicar a presença de outliers nas variáveis dependentes.

A seguir, o boxplot e o teste de Z-score indicaram a ausência de outliers visíveis, assim como não foram encontrados pontos no dataset com mais ou menos de 3 desvios padrão (Z-scores).

2.1 Análise de Correlação




Figura 1: Matriz de Correlação.

A partir dos gráficos e da análise de correlação com as variáveis target, podemos destacar os seguintes pontos:

- X1 e X2 apresentam correlação negativa extremamente alta ($r \approx -0,99$), o que pode indicar redundância para o modelo.
- X4 tem forte correlação com X2 e X5, o que é esperado, uma vez que representam área do telhado, superfície e altura total.
- X5 possui correlação muito forte com as variáveis target Y1 e Y2 ($r \approx 0,89$), indicando que a altura geral é um ótimo preditor para ambas.
- Y1 e Y2 são altamente correlacionadas entre si ($r = 0,98$), o que sugere que estão relacionadas a um mesmo fenômeno físico ou comportamento semelhante.
- X1 tem correlação moderada com Y1 e Y2 ($r \approx 0,62$).
- X3 apresenta correlação moderada com Y1 e Y2 ($r \approx 0,45$).
- As variáveis X6, X7 e X8 mostram pouca ou nenhuma correlação com as variáveis target ou com outras variáveis do conjunto. Testes adicionais serão necessários para decidir sobre o descarte ou manutenção dessas variáveis.
- Dada a forte correlação entre Y1 e Y2 ($r = 0,98$), é viável priorizar um modelo de predição multi-saída (multi-output).

O possível problema encontrado com essa análise é que as variáveis como X1, X2, X4 e X5 apresentam alta correlação entre si, indicando possível presença de multicolinearidade. A multicolinearidade pode afetar negativamente modelos de regressão, principalmente aqueles baseados em métodos lineares, pois dificulta a interpretação dos coeficientes e pode tornar o modelo instável, sensível a pequenas variações nos dados. Como consequência, o modelo pode superestimar ou subestimar a influência de certas variáveis.

Pode ser que seja necessário aplicar técnicas como:

- Remoção de variáveis altamente correlacionadas, mantendo apenas a mais representativa;
- Aplicação de métodos de regularização, como *Ridge* ou *Lasso*, que penalizam coeficientes grandes e reduzem o impacto da multicolinearidade;

- Utilização de métodos de redução de dimensionalidade, como Análise de Componentes Principais (PCA), que transforma as variáveis correlacionadas em um novo conjunto de variáveis ortogonais;
- Avaliação da Variância Inflacionária (VIF) para quantificar a multicolinearidade e embasar decisões de remoção de variáveis.

2.2 Distribuição das Variáveis Target

A análise do plot das distribuições das variáveis target indica que nenhuma delas apresenta características de uma distribuição gaussiana.

Em vez disso, ambas parecem seguir uma distribuição bimodal, com dois picos principais de frequência: um entre os valores 10 e 20, e outro entre 30 e 40. Esse comportamento pode sugerir a existência de dois tipos distintos de construções no conjunto de dados.

A variável Y1 apresenta uma distribuição levemente assimétrica à direita, com o segundo pico centrado em torno de 30. Já Y2 é mais simétrica em comparação a Y1, embora também apresente uma cauda à direita.

Apesar das diferenças sutis, ambas as variáveis possuem formatos de distribuição semelhantes, o que era esperado dada a alta correlação entre elas ($r = 0,98$). Essa forte correlação pode indicar que os modelos preditivos para Y1 e Y2 serão bastante próximos em estrutura.

Como as distribuições não seguem uma normal padrão, algoritmos que assumem essa hipótese — como regressão linear simples ou métodos baseados em inferência paramétrica — podem ter seu desempenho impactado. Nesses casos, pode ser necessário aplicar transformações nas variáveis ou utilizar modelos que não assumem normalidade nas distribuições.

2.3 Distribuição das Features

A partir dos plots de distribuição das features, podemos observar que:

- A variável X5 (Overall Height) apresenta dois picos bem definidos, sugerindo que pode representar dois tipos distintos de construções. Além disso, a alta correlação da variável com as targets ($r \approx 0,90$) pode fornecer uma pista para explicar o comportamento bimodal observado nas duas variáveis target. Um possível tratamento para esse comportamento seria o treinamento de dois modelos separados para cada tipo de construção.

- A variável X4 (Roof Area) também apresenta dois picos, embora não tão bem definidos quanto em X5. Da mesma forma, essa distribuição pode influenciar o comportamento bimodal das variáveis target, dado a alta correlação inversa com as targets ($r \approx -0,89$).

3 Multicolinearidade e Análise de VIF

O teste de Variance Inflation Factor (VIF), onde idealmente valores menores que 5 são desejáveis, confirma a presença de grande multicolinearidade entre as variáveis. Esse problema pode ser melhor visualizado no heatmap anterior, que ilustra a forte correlação entre as variáveis.

Portanto, para o treinamento do modelo, pode ser necessário realizar o tratamento dessas variáveis, seja removendo-as diretamente, seja utilizando técnicas como Análise de Componentes Principais (PCA) ou outras abordagens de redução de dimensionalidade.

3.1 Feature Importance com Random Forest

Para realizar a análise de importância das variáveis, os dados foram normalizados utilizando o `StandardScaler`, devido às grandes diferenças nas escalas das variáveis. Considerando as análises de correlação e o `Feature Importance` obtido com o modelo Random Forest, a tabela a seguir resume os resultados e possíveis tratamentos:

Feature	Importância	Comentário
X1	0.469	Maior relevância, altamente colinear com X2, X4, X5.
X5	0.199	Importante e com pouca colinearidade. - Manter
X2	0.143	Importante, colinear com X1, X3, X4.
X4	0.066	Menor importância e colinear com X1, X2, X5 — candidato à remoção.
X7	0.065	Pequena importância, baixa colinearidade — Manter.
X3	0.037	Menor importância e baixa colinearidade — candidato à remoção.
X8	0.014	Irrelevante e sem correlação com targets — Remover.
X6	0.006	Irrelevante e sem correlação com targets — Remover.

Tabela 1: Análise de Importância das Features com Random Forest

3.2 Feature Importance com XGBoost

O `StandardScaler` também foi usado para o plot de `Feature Importance` do XGBoost, a tabela a seguir resume os resultados:

Feature	Importância	Comentário
X1	0.867	Principal feature, altamente colinear com X2, X4, X5.
X7	0.086	Pequena importância, baixa colinearidade — Manter.
X4	0.022	Menor importância e colinear — candidato à remoção.
X3	0.015	Menos importante e baixa colinearidade — candidato à remoção.
X8	0.005	Irrelevante e sem correlação com targets — Remover.
X6	0.004	Irrelevante e sem correlação com targets — Remover.
X5	0.000	Irrelevante mas com alta correlação com targets — candidato à remoção.
X2	0.000	Irrelevante e com correlação média com targets — candidato à remoção.

Tabela 2: Análise de Importância das Features com XGBoost

3.3 Considerações Finais da Análise Exploratória

As tabelas de **Feature Importance** indicam possíveis tratamentos para as variáveis específicas, seja com base em suas correlações com outras variáveis, seja pela sua importância nos dois modelos considerados. A partir daqui, podemos avançar para o próximo passo, que consiste no treinamento e teste dos modelos.

Caso os resultados obtidos não sejam satisfatórios, novas técnicas de tratamento poderão ser testadas. Inicialmente, testaremos modelos com duas saídas, Y1 e Y2, o que é justificado pela alta correlação entre as variáveis target ($r = 0,98$). Avaliaremos cenários de treinamento completo, remoção de variáveis ou uso de PCA. Com base nas métricas obtidas nesse teste, caso necessário, poderemos explorar o treinamento das variáveis separadamente ou avaliar outras técnicas.

4 Preparação dos Dados e Treinamento dos Modelos

Os modelos de regressão utilizados neste estudo foram escolhidos devido às suas características e ao desempenho esperado para problemas de regressão com múltiplas saídas. A seguir, apresentamos uma breve descrição de cada modelo e suas indicações para o contexto em questão.

- **Random Forest:** O Random Forest é um modelo de ensemble baseado em múltiplas árvores de decisão, onde cada árvore é treinada com uma amostra aleatória dos dados e uma seleção aleatória de características. Ele é robusto a overfitting e pode capturar não-linearidades complexas. Para problemas com múltiplas saídas, o Random Forest pode ser uma boa escolha, já que ele pode lidar com interações complexas entre as variáveis dependentes (Y1 e Y2). No entanto, seu desempenho pode ser sensível à escolha de parâmetros e ao número de árvores.
- **Gradient Boosting:** O Gradient Boosting é outro modelo de ensemble, mas,

ao contrário do Random Forest, ele cria as árvores sequencialmente, corrigindo os erros das árvores anteriores. Ele tem a vantagem de frequentemente apresentar bom desempenho em problemas de regressão, especialmente quando as relações entre as variáveis são complexas. Para múltiplas saídas, o Gradient Boosting pode ser eficaz, mas o ajuste dos hiperparâmetros pode ser mais sensível, exigindo um cuidado extra na escolha de parâmetros como a taxa de aprendizado.

- **Ridge Regression:** O Ridge é um modelo linear regularizado que aplica uma penalização à magnitude dos coeficientes das variáveis independentes. Isso ajuda a reduzir o overfitting, especialmente quando existem muitas variáveis correlacionadas. Para um problema com múltiplas saídas, o Ridge pode ser útil se as relações entre as variáveis forem aproximadamente lineares. No entanto, pode não capturar bem relações não-lineares entre as variáveis, o que limita seu uso em contextos mais complexos.
- **SVR (Support Vector Regression):** O SVR utiliza a técnica das Máquinas de Vetores de Suporte (SVM), que tenta encontrar uma função de regressão que seja robusta a outliers e que tenha um bom desempenho em alta dimensionalidade. O SVR pode ser eficaz em problemas de regressão onde as relações entre as variáveis são não-lineares. No caso de múltiplas saídas, o SVR pode ser estendido, mas seu desempenho pode ser afetado pelo ajuste dos parâmetros, como o valor de C e o tipo de kernel.
- **XGBoost:** O XGBoost é um algoritmo de boosting que utiliza árvores de decisão, mas com uma abordagem mais avançada e otimizada para minimizar o erro de predição. Ele é conhecido por seu alto desempenho em muitas competições de machine learning, sendo especialmente eficaz em dados com grande dimensionalidade ou com relações não-lineares. O XGBoost pode ser uma excelente opção para problemas de regressão com múltiplas saídas, dada sua capacidade de capturar padrões complexos, mas exige uma atenção cuidadosa ao ajuste de parâmetros para evitar overfitting.

Cada um desses modelos possui características distintas que os tornam mais ou menos adequados dependendo das especificidades do problema de regressão. A escolha do modelo a ser utilizado dependerá dos resultados das métricas, da complexidade dos dados e do comportamento das variáveis alvo ($Y1$ e $Y2$).

Para os modelos, foram testadas três abordagens, todas utilizando o `StandardScaler` para normalização das escalas. Para todas as abordagens, a divisão foi de 80% para treinamento e 20% para teste do conjunto de dados.

As três abordagens testadas foram:

- Treinamento completo, sem nenhum tratamento profundo.
- Treinamento com exclusão de variáveis muito correlacionadas ou com pouca importância, conforme observado nos plots.
- Treinamento com redução de dimensionalidade (PCA), aplicado em variáveis altamente correlacionadas.

As escolhas de variáveis para remoção ou dimensionalização foram motivadas pelos resultados das correlações, **feature importances** e outras análises realizadas. Foram testadas várias combinações de variáveis, e neste relatório serão descritas aquelas que se sobressaíram, considerando as métricas avaliadas.

4.1 Métricas Utilizadas

As métricas utilizadas para avaliar o desempenho dos modelos foram calculadas tanto de forma individual (para cada variável target) quanto pela média entre as variáveis. Isso é importante devido à presença de duas saídas (Y1 e Y2), o que pode influenciar o cálculo das métricas. A seguir, apresentamos as métricas utilizadas, seu significado e a importância de cada uma delas em diferentes contextos de problemas.

- **R² Score**: Mede a proporção da variabilidade dos dados que é explicada pelo modelo. O valor do R² pode variar entre 0 e 1, onde 1 indica que o modelo explica toda a variabilidade dos dados. Para múltiplas saídas, pode ser calculado tanto individualmente quanto como média. Essa métrica é útil para problemas de regressão em que se deseja verificar o quão bem o modelo está se ajustando aos dados.
- **MAE (Mean Absolute Error)**: Mede a média das diferenças absolutas entre os valores reais e os preditos. Quanto menor o valor do MAE, melhor o modelo. O MAE é robusto a outliers e é uma boa métrica para medir erros médios de previsão em problemas de regressão.
- **MSE (Mean Squared Error)**: Mede a média dos erros quadráticos. A diferença entre o MSE e o MAE é que o MSE penaliza mais os grandes erros devido ao quadrado da diferença. Embora sensível a outliers, o MSE é útil quando se deseja dar mais importância a erros maiores.

- **RMSE (Root Mean Squared Error):** É a raiz quadrada do MSE e traz a métrica de volta para a mesma unidade das variáveis de entrada. Assim como o MSE, o RMSE penaliza mais os grandes erros e é útil quando se deseja medir o erro em uma escala comparável com os dados originais.
- **MedAE (Median Absolute Error):** Mede a mediana dos erros absolutos, sendo menos sensível a outliers em comparação ao MAE. Essa métrica é útil quando se deseja avaliar o erro mediano, sendo uma boa alternativa ao MAE em dados com outliers.
- **MSLE (Mean Squared Logarithmic Error):** Mede a diferença entre os logaritmos dos valores reais e preditos. Essa métrica é útil quando os dados seguem uma distribuição logarítmica e queremos penalizar previsões que estão longe de zero. Importante para dados com grande variação e/ou escalas multiplicativas.
- **Max Error:** Mede o maior erro absoluto entre as previsões e os valores reais. Essa métrica é útil para detectar piores previsões em termos absolutos e pode ser relevante em problemas onde os piores erros são particularmente críticos.

Essas métricas são calculadas de forma crua para cada saída (Y_1 e Y_2) e também podem ser combinadas em um valor médio, o que ajuda a avaliar o desempenho geral do modelo.

4.2 Resultados dos Testes dos Modelos

Aqui descrevemos os resultados obtidos em cada abordagem.

4.2.1 Resultados com Todas as Variáveis

Nos gráficos apresentados, a linha tracejada vermelha representa a reta de referência onde os valores reais são iguais aos valores preditos ($y_{\text{real}} = y_{\text{pred}}$), enquanto os pontos azuis representam as previsões do modelo. Quanto mais próximos os pontos estiverem dessa linha, melhor o desempenho preditivo do modelo.

Pela análise dos gráficos de barras e da distribuição dos pontos nos gráficos de previsão versus valor real, observa-se que, embora os modelos *RandomForest* e *GradientBoosting* tenham apresentado resultados satisfatórios, o modelo *XGBoost* obteve desempenho superior. Considerando o valor médio das métricas para as duas variáveis-alvo, o *XGBoost* apresentou os melhores resultados em 6 das 7 métricas

avaliadas. A única exceção foi a métrica *Max Error Avg*, na qual o modelo *GradientBoosting* teve desempenho levemente superior.

O alto valor de R^2 poderia, à primeira vista, levantar a hipótese de overfitting. No entanto, tal hipótese foi descartada com base na distribuição dos pontos nos gráficos de predição, os quais mostraram boa aderência à reta ideal.

4.2.2 Resultados com Redução de Dimensionalidade (PCA)

Foi realizada uma redução de dimensionalidade utilizando Análise de Componentes Principais (PCA), aplicada sobre variáveis fortemente correlacionadas, dos testes o melhor resultado foi com a combinação $X1$ e $X2$, conforme indicado na análise exploratória. Os resultados obtidos foram comparados diretamente com os da abordagem com todas as variáveis e com a abordagem de exclusão.

As métricas resultantes do uso de PCA mostraram uma ligeira melhoria em relação ao modelo completo, porém essa diferença foi observada apenas na terceira casa decimal. Considerando a ordem de grandeza das variáveis-alvo e das métricas, como o *MAE*, essa variação foi considerada irrelevante para aplicações práticas.

Foram testadas também outras combinações de variáveis para aplicação do PCA, mas nenhuma delas apresentou desempenho superior ao modelo com todas as variáveis.

4.2.3 Resultados com Exclusão de Variáveis

Foi avaliada a exclusão de variáveis consideradas redundantes com base na análise exploratória. O melhor resultado obtido das combinações foi especificamente com a remoção das variáveis $X4$ e $X5$, mantendo o restante do conjunto de dados.

Os resultados mostraram uma melhoria nas métricas em comparação ao modelo com todas as variáveis, de forma semelhante ao observado na abordagem com PCA. Contudo, diferentemente da redução de dimensionalidade, observou-se também uma melhoria nas métricas de *Max Error*. Além disso, a exclusão de duas variáveis, sem perda de desempenho do modelo, pode trazer vantagens práticas como redução do tempo de treinamento e simplificação do processo de coleta de dados na aplicação final.

Foram testadas ainda outras combinações de exclusão de variáveis, mas nenhuma resultou em melhorias superiores às obtidas com a exclusão de $X4$ e $X5$.

4.2.4 Conclusão dos Testes

Com base nos testes realizados, conclui-se que o modelo com exclusão das variáveis X_4 e X_5 apresentou o melhor desempenho global, considerando tanto a manutenção da qualidade preditiva quanto as vantagens operacionais associadas à simplificação do conjunto de dados. Esse modelo é, portanto, o selecionado como modelo final para o problema em questão. Após o treinamento, ele foi exportado e integrado a um módulo responsável por realizar as previsões, o qual é acionado diretamente pela API.

5 Características da API Django

O sistema apresenta as seguintes características principais:

- **Autenticação JWT:** A API utiliza tokens JWT (JSON Web Tokens) para garantir que apenas usuários autenticados possam acessar os endpoints.
- **Predição com Modelo de Machine Learning:** O modelo de regressão previamente treinado é carregado e utilizado para gerar previsões com base nos dados fornecidos pelos usuários.
- **Persistência de Dados:** Todas as entradas e saídas das previsões e de cadastro de usuários são armazenadas em um banco de dados PostgreSQL.
- **Listagem e Exclusão de Previsões:** Usuários podem listar todas as suas previsões realizadas e excluir registros específicos conforme necessário.
- **Adição e Exclusão de Usuários:** Administradores podem listar usuários, adicionar, excluir e modificar cadastros.
- **Documentação Swagger:** A API inclui documentação interativa com Swagger, facilitando o uso e o entendimento dos endpoints. Pode ser acessada por <http://localhost:8000/swagger/>.
- **Implementação em Docker:** O projeto foi containerizado com Docker para facilitar a execução, portabilidade e implantação em diferentes ambientes.

5.1 Arquitetura do Sistema

A arquitetura do sistema foi organizada em módulos para garantir modularidade, escalabilidade e manutenibilidade. Os principais componentes são:

5.1.1 Modelo de Usuário Personalizado

O sistema utiliza um modelo de usuário personalizado (`CustomUser`) que substitui o campo padrão `username` pelo `email` como identificador único. Além disso,

campos obrigatórios como `nome_completo` e `telefone` foram adicionados para atender aos requisitos de cadastro.

5.1.2 Modelo de Predição

O modelo `Prediction` foi criado para armazenar as entradas fornecidas pelos usuários e os resultados gerados pelo modelo de regressão. Ele inclui os seguintes campos:

- `user`: Usuário que realizou a predição (relacionamento com o modelo `CustomUser`).
- `input_data`: Dados de entrada fornecidos pelo usuário no formato JSON.
- `output_data`: Resultados gerados pelo modelo no formato JSON.
- `created_at`: Data e hora da criação do registro.

Os resultados das predições ficam armazenados no banco de dados, e podem ser visualizados ou excluídos pelo próprio usuário logado. Os usuários podem acessar os registros apenas de suas próprias predições.

5.1.3 Carga do Modelo de Regressão

O modelo de regressão e o scaler foram treinados previamente e salvos em arquivos `.pkl`. Durante a execução da API, esses arquivos são carregados usando a biblioteca `joblib`. O modelo é aplicado aos dados fornecidos pelo usuário após a transformação com o scaler.

5.2 Endpoints da API

Os endpoints da API foram desenvolvidos utilizando o Django REST Framework (DRF) e incluem:

- **POST** `/api/login/`: Realiza a autenticação do usuário e retorna um par de tokens JWT (access e refresh).
- **POST** `/api/refresh/`: Recebe o token de refresh e retorna um novo token de acesso válido.
- **GET** `/api/validate-token/`: Valida o token de acesso atual e retorna o status da autenticação.
- **POST** `/api/logout/`: Realiza o logout do usuário invalidando o token de refresh atual.
- **GET/POST** `/api/users/`: Lista todos os usuários cadastrados (GET) ou cria um novo usuário (POST).
- **GET/PUT/DELETE** `/api/users/<id>/`: Recupera (GET), atualiza (PUT) ou exclui (DELETE) um usuário específico com base no seu ID.

- **POST /api/predict/**: Recebe os dados de entrada, realiza a predição e armazena os resultados no banco de dados.
- **GET /api/predictions/**: Lista todas as predições realizadas pelo usuário logado.
- **DELETE /api/predictions/<id>/**: Exclui uma predição específica com base no ID.

5.3 Banco de Dados

O sistema utiliza o banco de dados PostgreSQL para armazenar os dados. As migrações do Django foram utilizadas para criar as tabelas necessárias no banco de dados.

6 Conclusão

Uma das principais dificuldades encontradas durante o desenvolvimento deste case foi o tamanho reduzido da base de dados, com aproximadamente 700 linhas. Isso dificultou a análise dos resultados dos modelos de predição. Embora o R^2 muito próximo de 1 possa indicar overfitting, este não parece ser o caso. No entanto, seria recomendável realizar novos testes com diferentes proporções de divisão treino/teste ou com a inclusão de novos dados relacionados ao mesmo problema. Além disso, a interface também pode ser aprimorada, com melhorias nos menus de navegação, criação de novas páginas ou novas funcionalidades como opções de filtragem de predições.